

Classificação Inteligente de Sementes de Cacau no Teste de Corte Utilizando Redes Neurais Convolucionais como Extratoras de Características e Máquinas de Vetores de Suporte

Alexandre Teixeira da Silva¹, Cesar Braz de Oliveira²,
Ícaro Guimarães Canto³, Priscila Leylianne da Silva. Gonçalves⁴

¹Universidade do Estado do Amazonas - UEA
Av. Darcy Vargas, 1200, Parque Dez de Novembro – 69.065-20 - Manaus - AM -Brasil

{atds.cid25¹, cbdo.cid25², igc.cid25³, pldsg.cid25⁴}@uea.edu.br

Resumo. Este trabalho aborda a classificação automática de amêndoas de cacau no Teste de Corte como uma tarefa de Visão Computacional utilizando Redes Neurais Convolucionais (CNNs) pré-treinadas como extratoras de características combinadas com Máquinas de Vetores de Suporte (SVMs) como classificadores. Utilizando uma base de dados balanceada com 1.400 imagens em 14 classes, foram realizados experimentos com fusão de características das arquiteturas InceptionV3, VGG16 e EfficientNetB0. O melhor resultado alcançou 77,14% de acurácia utilizando ensemble stacking, demonstrando a viabilidade da abordagem CNN+SVM para este domínio agrícola.

Abstract. his work addresses the automatic classification of cocoa beans in the Cut-Test as a Computer Vision task using pre-trained Convolutional Neural Networks (CNNs) as feature extractors combined with Support Vector Machines (SVMs) as classifiers. Using a balanced dataset with 1,400 images across 14 classes, experiments were conducted with feature fusion from InceptionV3, VGG16, and EfficientNetB0 architectures. The best result achieved 77.14% accuracy using ensemble stacking, demonstrating the viability of the CNN+SVM approach for this agricultural domain.

1. Introdução

O cacau (*Theobroma cacao*) representa um insumo estratégico para a cadeia produtiva do chocolate e derivados, a competitividade no mercado global depende diretamente da qualidade das amêndoas produzidas [MAPA 2008, Saito et al 2019]. O teste de corte constitui etapa central na avaliação dessa qualidade, onde o especialista corta amêndoas longitudinalmente e inspeciona visualmente as características externas, como cor, compartimentação e defeitos associados à fermentação [Malcher and Guedes 2022].

A técnica utilizada, o teste de corte apresenta limitações práticas. A inspeção manual depende de mão de obra altamente especializada, consome tempo considerável e está sujeito a habilidade humana, comprometimento com a padronização e escalabilidade. As técnicas de visão computacional e aprendizado de máquina oferecem oportunidade consolidada para automatizar e apoiar a classificação de amêndoas no teste de corte [Santos 2019, Malcher and Guedes 2022].

A escolha promissora consiste em trabalhar CNNs pré-treinadas em grandes bases de dados como extratoras de características visuais, alimentando classificadores tradicionais como

SVMs. Explicam que essa estratégia de transfer learning demonstra eficiência quando a tarefa-alvo dispõe de poucos exemplos [Sarkar and Bali and Ghosh 2018].

O objetivo de este trabalho fundamentar-se em implementar e examinar um pipeline de classificação sementes de cacau no teste de corte que combina CNNs pré-treinadas VGG16, VGG19, ResNet50, InceptionV3 e MobileNetV2 como extratoras de características de dados visuais com SVMs multiclasse, buscando atingir o baseline de 89,79% de acurácia [Malcher and Guedes 2022].

A base de dados de imagens de amêndoas de cacau classificadas na prova de corte, contendo de 1400 imagens distribuídas em 14 classe diferentes, com 100 imagens por classe, segue: (Agglutinated, Brittle, Compartmentalized_Brown, Compartmentalized_PartiallyPurple, Compartmentalized_Purple, Compartmentalized_Slaty, Compartmentalized_White, Flattened, Moldered, Plated_Brown, Plated_PartiallyPurple, Plated_Purple, Plated_Slaty e Plated_White.). Média de cores nos canais RGB e medidas geométricas para alimentar redes neurais do tipo perceptron multicamada, atingindo acurácia de 99,64% [Santos et al 2019].

2. Trabalhos Relacionados

Os trabalhos que abordam o teste de corte como visão computacional extraem características, de média de componentes de cor e o perímetro das sementes, os estudos de redes neurais destacam-se com melhores resultados analisados nos experimentos, porém com redes neurais convolucionais profundas, avaliam arquiteturas como LeNet, AlexNet, MobileNet, VGG-16, Inception e EfficientNet. Os autores da pesquisa reportaram que Inception ($68,28\% \pm 3,21$) VGG-16 ($65,54\% \pm 3,05$) e EfficientNetB0 ($55,04\% \pm 2,03$) abordam como as três melhores arquiteturas em acurácia individual. A combinação desse resultado em um comitê com votação majoritária suave resultou em acurácia média de ($89,79\% \pm 0,92$), superando todos os modelos individuais avaliados, desse valor constitui o baseline de referência para o trabalho presente [Malcher and Guedes 2022].

Trabalhos previamente encontrados na literatura que abordam o problema do teste de corte como tarefa de Visão Computacional utilizam a extração de características das imagens para obtenção de atributos preditores. Destacaram características texturais de Haralick, obtidas a partir da matriz de ocorrência de níveis de cinza, além de componentes de cor e características estruturais das sementes [Santos et al 2019]. Em ambos os trabalhos, redes neurais artificiais multilayer perceptron obtiveram os melhores resultados experimentais: 99,73% e 92,97% de acurácia, respectivamente. Porém, há indicação de possível ocorrência de overfitting para as configurações avaliadas [Santos et al 2018 e 2019].

O trabalho abordou o problema utilizando CNNs do estado da arte, incluindo LeNet, AlexNet, MobileNet, VGG-16, Inception, EfficientNetB0 e EfficientNetB3. Os autores utilizaram validação cruzada holdout com 70% para treino, 10% para validação e 20% para teste, com 5 repetições. As técnicas de regularização incluíram Early Stopping com paciência de 100 épocas, Model Checkpoint e Dropout. Os resultados mostraram Inception ($68,28\% \pm 3,21$), VGG-16 ($65,54\% \pm 3,05$) e EfficientNetB0 ($55,04\% \pm 2,03$) como as três melhores arquiteturas individuais. A combinação destas em um comitê com votação majoritária suave alcançou acurácia de $89,79\% \pm 0,92$, superando todos os modelos individuais [Malcher e Guedes 2022].

Neste trabalho aplica-se 4 (notebooks) scripts na linguagem Python disponível em https://github.com/Priscilaleylianne/Projeto_Machine_Learning_Aplicacao_02, resolução dos experimentos da busca de alcance do baseline no Melhor resultado de 77,14% de acurácia com ensemble Stacking, projeto de classificação de sementes de cacau (CNN + SVM), incluindo análise exploratória, extração de features, treinamento de SVM e avaliação.

3. Metodologia

3.1 Base de Dados

O estudo deste trabalho utilizou a base de dados Cut-Test-Classified Cocoa Beans [Santos et al. 2019b], contendo 1.400 imagens de sementes de cacau no teste de corte, rotuladas por especialistas em 14 classes: Aglutinada, Quebradiça, Compartimentalizada (marrom, parcialmente violeta, violeta, ardósia, branca), Achatada, Embolorada, e Chocha com as mesmas variações de cor. As classe apresentadas representam combinações de aparência relacionada a cor compartimentação, incluindo rótulos para identificação como Agglutinated, Brittle, Compartmentalized_Brown, Compartmentalized_PartiallyPurple, Compartmentalized_Purple, Compartmentalized_Slaty, Compartmentalized_White, Flattened, Moldered, Plated_Brown, Plated_PartiallyPurple, Plated_Purple, Plated_Slaty e Plated_White. A base está balanceada com 100 exemplos por classe. Figura 1, exibindo as classes contidas na base de dados. Figura 2, visualizando quantidade de imagens por classe.

```
=====
CLASSES ENCONTRADAS NO DATASET
=====
1. Agglutinated
2. Brittle
3. Compartmentalized_Brown
4. Compartmentalized_PartiallyPurple
5. Compartmentalized_Purple
6. Compartmentalized_Slaty
7. Compartmentalized_White
8. Flattened
9. Moldered
10. Plated_Brown
11. Plated_PartiallyPurple
12. Plated_Purple
13. Plated_Slaty
14. Plated_White
=====
Total de classes: 14
```

Figura 1 – Dataset cacau.

DISTRIBUIÇÃO DE IMAGENS POR CLASSE		
Agglutinated	:	100 imagens (7.14%)
Brittle	:	100 imagens (7.14%)
Compartmentalized_Brown	:	100 imagens (7.14%)
Compartmentalized_PartiallyPurple	:	100 imagens (7.14%)
Compartmentalized_Purple	:	100 imagens (7.14%)
Compartmentalized_Slaty	:	100 imagens (7.14%)
Compartmentalized_White	:	100 imagens (7.14%)
Flattened	:	100 imagens (7.14%)
Moldered	:	100 imagens (7.14%)
Plated_Brown	:	100 imagens (7.14%)
Plated_PartiallyPurple	:	100 imagens (7.14%)
Plated_Purple	:	100 imagens (7.14%)
Plated_Slaty	:	100 imagens (7.14%)
Plated_White	:	100 imagens (7.14%)
TOTAL DE IMAGENS: 1400		
INTERVALO POR CLASSE: 100 a 100 imagens		

Figura 2- Distribuição de imagens.

3.2 Arquiteturas CNN

A utilização de seis arquiteturas CNN pré-treinadas no ImageNet como extratoras de características, sem as camadas finais de classificação e com pesos congelados:

InceptionV3, VGG16, EfficientNetB0, MobileNetV2, EfficientNetB3 e DenseNet121. A Tabela 1 do documento sintetiza o tamanho de entrada de cada rede, a dimensão do vetor de features gerado e observações sobre sua origem:

- InceptionV3 (299×299, 2.048 features, top-3 do trabalho de referência).
- VGG16 (224×224, 512 features, top-3 do trabalho de referência).
- EfficientNetB0 (224×224, 1.280 features, top-3 do trabalho de referência).
- MobileNetV2 (224×224, 1.280 features).
- EfficientNetB3 (300×300, 1.536 features).
- DenseNet121 (224×224, 1.024 features, incluída como alternativa).

Tabela 1 - Arquiteturas CNN utilizadas como extratoras de características.

Arquitetura	Input Size	Dimensão Features	Observação
InceptionV3	299×299	2048	Top 3
VGG16	224×224	512	Top 3
EfficientNetB0	224×224	1280	Top 3
MobileNetV2	224×224	1280	-
EfficientNetB3	300×300	1536	-
DenseNet121	224×224	1024	Adicional

LeNet e AlexNet, mencionadas no trabalho de referência, não possuem implementação com pesos pré-treinados no ImageNet disponível no Keras Applications, sendo substituídas por DenseNet121. Tabela 1.

3.3 Feature Fusion e PCA

As características extraídas das três melhores CNNs (InceptionV3, VGG16 e EfficientNetB0) foram concatenadas, resultando em um vetor de 3.840 dimensões (2048 + 512 + 1280). Subsequentemente, foi aplicada normalização via StandardScaler e redução de dimensionalidade via PCA.

Os testes de diferentes valores de componentes PCA (50, 100, 200, 300 e 700), avaliando o trade-off entre variância explicada e acurácia de classificação. O valor de 700 componentes foi selecionado, retendo 96,35% da variância total e obtendo a melhor acurácia (77,86%) entre as configurações avaliadas. Figura 3.

```
=====
REDUÇÃO DE DIMENSIONALIDADE COM PCA
=====

Número de amostras de treino: 1120
Número de features original: 3840

Testando diferentes valores de n_components...

PCA( 50): variância=55.07%, acc=72.14%
PCA(100): variância=65.89%, acc=72.86%
PCA(200): variância=77.12%, acc=75.36%
PCA(300): variância=83.93%, acc=76.07%
PCA(700): variância=96.35%, acc=77.86%

Melhor PCA: 700 componentes
Variância explicada: 96.35%
Acurácia: 77.86%
```

Figura 3 - Valores PCA.

3.4. Busca em Grade para SVM

Elaborada uma busca em grade sistemática para otimização dos hiperparâmetros do SVM, conforme especificado na Tabela 2. A grade contemplou:

Tabela 2 - Grade de hiperparâmetros para otimização do SVM.

Parâmetro	Valores	Justificativa
C	0.1, 1, 10, 100, 1000	Faixa logarítmica
Kernel	rbf, linear, poly	Diferentes separações
Gamma	scale, auto, 0.01, 0.001, 0.0001	Coefficiente do kernel
Degree	2, 3, 4	Grau do kernel poly

A validação foi realizada com 5-fold cross-validation estratificado, totalizando 225 combinações de hiperparâmetros e 1.125 ajustes por configuração de features. Figura 4.

```

=====
GRID SEARCH - MÚLTIPLAS CONFIGURAÇÕES
=====

Configuração: Fused (Inception+VGG16+EfficientNet)
Shape: (1120, 3840)
=====

Iniciando Grid Search...
Fitting 5 folds for each of 225 candidates, totalling 1125 fits

Melhores Hiperparâmetros:
C: 10
degree: 2
gamma: 0.0001
kernel: rbf

Resultados:
CV Score: 0.7580
Acurácia: 0.7571 (75.71%)
F1-Score: 0.7612
Tempo: 8.6 min

=====

Configuração: Fused + PCA(700)
Shape: (1120, 700)
=====

Iniciando Grid Search...
Fitting 5 folds for each of 225 candidates, totalling 1125 fits

Melhores Hiperparâmetros:
C: 0.1
degree: 2
gamma: scale
kernel: linear

Resultados:
CV Score: 0.7527
Acurácia: 0.7500 (75.00%)
F1-Score: 0.7546
Tempo: 1.2 min

```

Figura 4 - Grade configuração.

3.5. Estratégias de Ensemble

A implementação de duas estratégias de ensemble: (i) Soft Voting, que combina as probabilidades preditas de múltiplos classificadores; e (ii) Stacking, que utiliza um meta-classificador (Regressão Logística) treinado sobre as predições dos classificadores base (SVM RBF, SVM Linear, SVM Polinomial e Random Forest). Figura 5.

```

=====
TREINANDO CLASSIFICADORES PARA ENSEMBLE
=====

Usando configuração: Fused (Inception+VGG16+EfficientNet)
Shape: (1120, 3840)

Treinando classificadores individuais...

SVM_RBF          Acuracia: 0.7536 (75.36%)  Tempo: 21.8s
SVM_Polinomial   Acuracia: 0.5571 (55.71%)  Tempo: 19.3s
SVM_Linear       Acuracia: 0.7429 (74.29%)  Tempo: 10.6s
RandomForest     Acuracia: 0.7000 (70.00%)  Tempo: 1.8s

```

Figura 5 - Classificação de treinamento.

4. Resultados e Discussão

4.1. Resultados do Grid Search

A Tabela 3 apresenta os resultados obtidos nas diferentes configurações de features avaliadas via Grid Search, para as duas principais configurações de features: fusão direta 3.840 dimensões e fusão seguida de PCA 700 componentes. A configuração Fused 3840 dim alcançou melhor desempenho com SVM RBF ($C=10$, $\gamma=0,0001$), obtendo CV Score de 75,80% e acurácia de 75,71% no conjunto de teste. A configuração Fused + PCA(700) apresentou melhor combinação com SVM linear ($C=0,1$), resultando em CV Score de 75,27% e acurácia de 75,00%.

Tabela 3 - Resultados do Grid Search para diferentes configurações de features.

Configuração	Melhores Parâmetros	CV Score	Acurácia
Fused (3840 dim)	$C=10$, rbf, $\gamma=0.0001$	75,80%	75,71%
Fused + PCA(700)	$C=0.1$, linear	75,27%	75,00%

Esses resultados indicam que a redução de dimensionalidade via PCA preservou a maior parte da informação discriminativa, ao mesmo tempo em que diminui a complexidade computacional, ainda que com leve redução de desempenho.

4.2. Resultados dos Classificadores Individuais

A Tabela 4 apresenta o desempenho dos classificadores individuais treinados sobre as features fusionadas. O SVM com kernel RBF obteve acurácia de 75,36% em aproximadamente 21,8 segundos de treinamento, sendo o melhor modelo individual em termos de desempenho. O SVM linear atingiu 74,29% com tempo de treinamento menor (10,6 s), enquanto o Random Forest alcançou 70,00% em 1,8 s, destacando-se pela rapidez. O SVM polinomial apresentou desempenho inferior (55,71%), sugerindo que o aumento da complexidade do kernel nem sempre se traduz em ganhos de acurácia para este problema.

Tabela 4 - Desempenho dos classificadores individuais.

Classificador	Acurácia	Tempo (s)	Observação
SVM RBF	75,36%	21,8	Melhor individual
SVM Linear	74,29%	10,6	-
Random Forest	70,00%	1,8	Mais rápido
SVM Polinomial	55,71%	19,3	-

A Tabela 5 apresenta o ranking dos três melhores modelos conforme acurácia, F1-Score e precisão. O ensemble por stacking ocupou a primeira posição, com 77,14% de acurácia, F1-Score de 77,36% e precisão de 78,18%, superando todos os classificadores individuais. O ensemble por soft voting alcançou 76,43% de acurácia, F1-Score de 76,53% e precisão de 77,25%, também acima dos modelos isolados. O SVM RBF, melhor classificador individual, registrou 75,36% de acurácia, 75,48% de F1-Score e 76,12% de precisão.

Tabela 5 - Ranking dos três melhores modelos.

Posição	Modelo	Acurácia	F1-Score	Precisão
1º	Stacking	77,14%	77,36%	78,18%
2º	Soft Voting	76,43%	76,53%	77,25%
3º	SVM RBF	75,36%	75,48%	76,12%

Esses resultados reforçam o argumento de que a combinação de classificadores complementares, especialmente por meio de stacking, melhora a capacidade de generalização do sistema de classificação de sementes de cacau.

4.4. Análise Comparativa com o Trabalho de Referência

A Tabela 6 apresenta uma comparação metodológica entre o trabalho de referência e o presente estudo [Malcher and Guedes 2022], utilizam CNNs end-to-end com fine-tuning, camada softmax acoplada e ensemble via soft voting, alcançando acurácia de 89,79%. Já este trabalho mantém os pesos das CNNs congelados, utiliza SVM como classificador final e adota stacking como principal estratégia de ensemble, atingindo 77,14% de acurácia.

Tabela 6 - Comparativo metodológico entre os trabalhos.

Aspecto	Trabalho de Referência	Este Trabalho
Abordagem	CNNs end-to-end	CNN features + SVM
Pesos CNN	Ajustados (fine-tuning)	Congelados (frozen)
Classificador	Softmax das CNNs	SVM
Ensemble	Soft voting	Stacking
Acurácia	89,79%	77,14%

O ajuste dos pesos da CNN (fine-tuning) permite que a rede aprenda características específicas do domínio de sementes de cacau, enquanto features extraídas com pesos fixos do ImageNet são mais genéricas. Adicionalmente, a camada softmax treinada junto com a CNN está otimizada para as mesmas features que a rede aprende, diferentemente do SVM que opera sobre representações pré-definidas.

4.5. Análise por Classe

A análise das matrizes de confusão revelou que algumas classes são classificadas com alta precisão (Plated_Slaty: 97,5%, Flattened: 100%, Agglutinated: 87%), enquanto outras apresentam maior dificuldade (Compartmentalized_PartiallyPurple: 42,9%, Plated_Purple: 60%). As classes com coloração parcialmente violeta tendem a ser confundidas entre si, indicando sobreposição nas características visuais extraídas pelas CNNs. A Figura 6 ilustra a matriz de confusão do melhor modelo, evidenciando tais padrões de erro.




Figura 6 - Matriz de confusão.

5. Considerações Finais

Este trabalho apresentou uma solução para classificação automática de sementes de cacau no teste de corte baseada em CNNs pré-treinadas como extratoras de características combinadas com SVMs como classificadores. A abordagem segue a metodologia de transfer learning, onde os pesos das CNNs são mantidos fixos e apenas o classificador final é treinado com os dados do domínio alvo.

Os principais resultados obtidos incluem:

1. Feature fusion das arquiteturas InceptionV3, VGG16 e EfficientNetB0 gerando vetores de 3.840 dimensões;
2. Otimização via PCA com 700 componentes retendo 96,35% da variância;
3. Grid Search com 225 combinações de hiperparâmetros para SVM;
4. Melhor resultado de 77,14% de acurácia com ensemble Stacking;
5. Identificação das classes mais desafiadoras para classificação automática.

A diferença de desempenho em relação ao baseline (89,79%) é explicada pela diferença metodológica fundamental: CNNs treinadas end-to-end versus CNNs como extratoras fixas. Ambas as abordagens têm suas aplicações: o fine-tuning oferece melhor desempenho quando há dados suficientes para ajuste, enquanto a extração de features é mais adequada para cenários com poucos exemplos ou restrições computacionais.

Como trabalhos futuros, sugere-se: (i) implementação de fine-tuning das últimas camadas das CNNs; (ii) utilização de data augmentation para aumentar a diversidade dos dados; (iii) exploração de arquiteturas mais recentes como Vision Transformers; e (iv) avaliação com imagens em condições menos controladas de iluminação.

6. Referências Bibliográficas

- Brainer, M. S. D. C. P. (2021). Produção de cacau. Caderno Setorial do Escritório Técnico de Estudos Econômicos do Nordeste, (149):1-23.
- Fu, Y. (2020). Image classification via fine-tuning with Efficientnet. Keras. Disponível em https://keras.io/examples/vision/image_classification_efficientnet_fine_tuning/. Acesso em 11 de janeiro de 2026.
- Malcher, D. and Guedes, E. (2022). Classificação inteligente do teste de corte do cacau com

redes neurais convolucionais profundas. In Anais do XIII Workshop de Computação Aplicada à Gestão do Meio Ambiente e Recursos Naturais, pages 31-40, Porto Alegre, RS, Brasil. SBC.

MAPA (2008). Instrução normativa n. 38, de 23 de junho de 2008. Ministério da Agricultura, Pecuária e Abastecimento.

Saito, S. (2019). Entendendo o relatório de classificação de amêndoas. Centro de Inovação do Cacau. Disponível em https://cic.pctsul.org/wpcontent/uploads/2019/11/Nota_tecnica_1_Como_e_feita_a_classificacao_no_CIC.pdf. Acesso em 11 de janeiro de 2026.

Santos, F. A., Palmeira, E. S., and Jesus, G. Q. (2018). Color, structural and textural features for the classification of a Cocoa beans image dataset using Artificial Neural Networks. In Anais do XIV WVC, pages 80-84, Ilhéus, Bahia.

Santos, F., Canuto, A., Bedregal, B., Palmeira, E., and Silva, I. (2019a). Supervised methods applied to the construction of a vision system for the classification of cocoa beans in the cut-test. In Anais do XVI ENIAC, pages 72-83, Porto Alegre, RS, Brasil. SBC.

Santos, F., Palmeira, E., and Jesus, G. (2019b). An Image Dataset of Cut-Test-Classified Cocoa Beans. Data in Brief, 24:103916.

Sarkar, D., Bali, R., and Ghosh, T. (2018). Hands-On Transfer Learning with Python: Implement advanced deep learning and neural network models using TensorFlow and Keras. Packt Publishing, Birmingham, 1st edition.